



DIACD

Aprendizaje No Supervisado



Documento II

Técnicas de agrupamiento o clustering



- 1.- Aplicación de las técnicas de agrupamiento
 - Por métodos aglomerativos
 - Por método de K-means
- 2.- Interpretación y análisis de los resultados
- 3.- Conclusiones



Equipo 15

Alfaro Prieto Gabriela - SI

Badillo Salas Casandra Medea - NO

Cruz Durán Emmanuel - NO

Pérez González Gabriela - SI

Rupit Rupit Livia Alejandra - SI



Profesor:

José Salvador Zamora
Muñoz




Contenido

1. **Introducción**
 - Contexto del problema.
2. **Aplicación de técnicas de agrupamiento, interpretación y análisis de resultados**
 - Métodos aglomerativos
 - K-meas
 - Comparativo
3. **Conclusiones**
4. **Referencias**

DIACD-Aprendizaje No Supervisado

Técnicas de agrupamiento o clustering "Students Habits vs Academic Performance"



Introducción:

Contexto del problema.

Para descubrir las características subyacentes* de los grupos generados en el Documento I, se debe aplicar algoritmos de agrupamiento lo cual se desarrollará en este informe.

Se compararán los resultados de dos de las principales técnicas de agrupamiento (*clustering*):

- **Métodos Jerárquicos Aglomerativos:** Una aproximación "de abajo hacia arriba" (*bottom-up*) que construye una jerarquía de clústeres a partir de las distancias individuales entre los registros, permitiendo visualizar la estructura de los datos a través de un dendrograma y determinar el nivel óptimo de agrupación.
- **Algoritmo de K-Means (K-Medios):** Un enfoque de particionamiento iterativo que busca minimizar la varianza intra-clúster (la suma de los errores cuadráticos), asignando a cada estudiante al centroide más cercano para generar agrupaciones compactas y claramente delimitadas.

Antes de aplicar K-Means se determina el número de grupos K. Consideramos tres enfoques:


- Método del codo (WSS/TSS).
- Validación cruzada mediante K-Fold.
- Índice de Silueta.

Esto permite seleccionar un número de grupos que produzca grupos compactos y bien separados.

*Es decir, qué hábitos específicos de estudio, sueño o uso de redes sociales definen a cada clúster.

Aplicación de técnicas de agrupamiento, interpretación y análisis de resultados:


Las metodologías que se mostrarán a continuación fueron aplicadas sobre el modelo UMAP, aplicado a los datos del procesamiento C, donde se normalizó todas las variables.



En el Documento 1, se menciona que empíricamente hay entre 3 y 4 grupos observables en la fragmentación de los alumnos, lo que nos hace suponer de la existencia de distintos "perfiles de hábitos" entre los estudiantes.

Algoritmos de métodos aglomerativos

La distancia considerada en este ejercicio es euclídeana.





Liga Completa o Compuesta (Vecinos más lejanos):
'complete'

La distancia euclidiana para 3 segmentos está en 8.

K-means

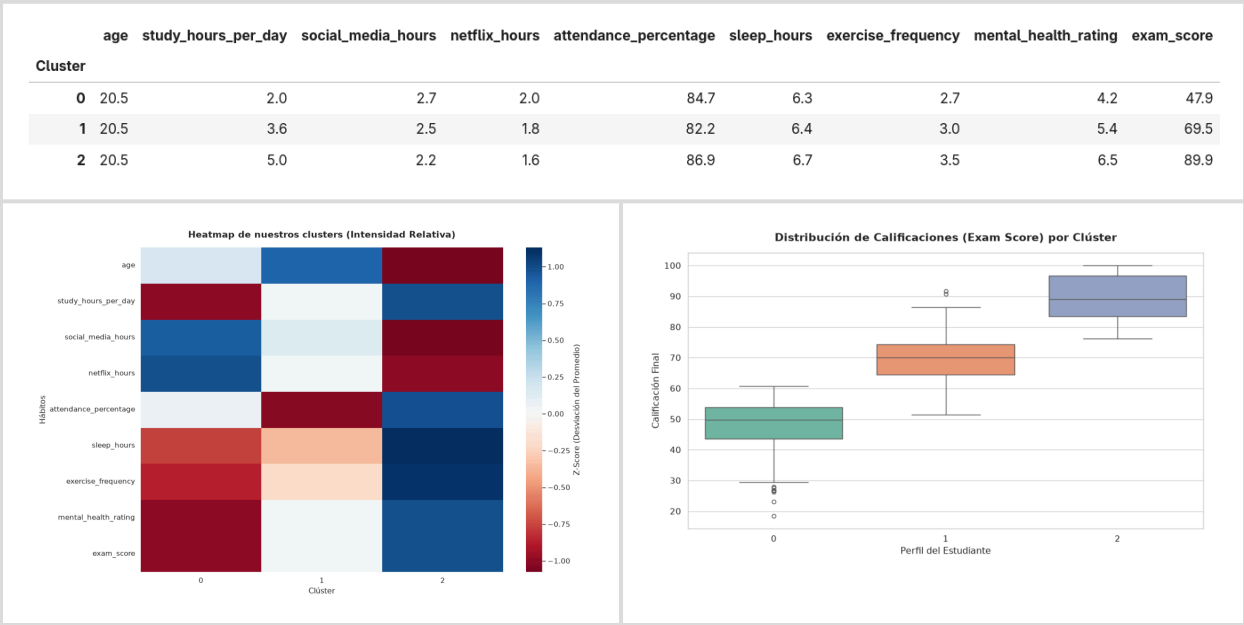
En K-means aplicado sobre UMAP, se diferencian 3 clusters.

Los alumnos en cada uno oscilan entre 255 y 469 individuos.



Se aprecia una distribución de los alumnos dentro del gráfico donde los que tienen con mayor calificación aparecen a la derecha y los de menor a la izquierda, disminuyendo de manera gradual en ese sentido.

Las siguientes variables muestran una diferencia notoria entre los tres segmentos:



Las características en los hábitos de los estudiantes muestran un comportamiento opuesto entre el cluster 0 y 2, siendo el cluster 1 el que está en medio de los dos anteriores. El rango de las calificaciones obtenidas muestra diferencias entre los tres clusters, siendo el de mejores resultados el cluster 2.

Por lo que los clusters podrían ser nombrados como:

Cluster 0 - **Alumno de bajo rendimiento**, representa al estudiante con hábitos poco saludables y bajo rendimiento.

Cluster 1 - **Alumno promedio**. representa al estudiante promedio

Cluster 2 - **Alumno de alto Rendimiento**. muestra buenos hábitos y excelencia académica.

Se calculó el Z-Score de las medias de cada grupo, lo que permite visualizar la intensidad relativa de cada hábito frente a la media poblacional.

Bajo rendimiento

Tienen desviaciones severas a la baja (rojo oscuro) en las variables **positivas**, como exam_score, mental_health_ratin, exercise_frequency y study_hours_per_day.

Simultáneamente, presentan los picos más altos (azul oscuro) en social_media_hours y netflix_hours.

Promedio rendimiento

Presenta neutralidad estadística (tonos blancos/grises) en casi todas las métrica.

Son el grupo de mayor edad (age) y los que tienen el porcentaje de asistencia más bajo (attendance_percentage)

Alto rendimiento


Se observa una relación visual directa entre los buenos hábitos y la excelencia académica. Cuenta con los valores máximos (azul oscuro) en las variables **positivas** como son: exam_score, mental_health_ratin, exercise_frequency, sleep_hours, attendance_percentage y study_hours_per_day.

Se demuestra una fuerte asociación entre el exceso de tiempo en pantallas, la falta de estudio, una salud mental deteriorada y el bajo rendimiento académico.

Representan al estudiante promedio de la mayor edad de la encuesta que logra mantener calificaciones medias a pesar de faltar a clases frecuentemente.

Su éxito académico está fuertemente respaldado por un estilo de vida disciplinado y saludable. Registran los niveles más bajos de la población (rojo oscuro) en consumo de ocio digital y edad.

Comparativo entre metodologías de clustering



Conclusiones

Se muestra una asociación entre el exceso de tiempo en pantallas, la falta de estudio, una salud mental deteriorada y el bajo rendimiento académico de la misma manera que con los opuestos en estos hábitos y el resultado en el examen.

Los modelos no supervisados lograron separar con éxito a los estudiantes basándose en sus hábitos. La matriz de calor confirma que en promedio, el rendimiento académico ("exam_score") no es un evento aleatorio, sino el resultado directo de los hábitos de los alumnos (estudio, sueño, asistencia y baja exposición a redes sociales), el cuál lograron aislar matemáticamente los algoritmos de agrupamiento.



Comparación de resultados

Reflexión


Modificando el procesamiento, tratamiento o especificaciones técnicas de modelado se encuentran diferentes resultados, es por esto que se consolidan en la siguiente tabla algunos ejercicios realizados. En algunos de estos, se encuentran alumnos de todos

los rangos de resultado en el "exam_score", en cada cluster lo que generaría resultados completamente diferentes a los mostrados previamente.

Pruebas adicionales I

Modificaciones realizadas	Resultados o diferencias con el modelo presentado
Comparativo vs Métodos aglomerativos y jerárquicos	
<u>PROCESAMIENTO C:</u> Variables codificadas, No normalizadas (~A)	
Liga Simple (Vecinos más cercanos): 'single'	 Dendrograma de Hábitos Estudiantiles (Método Single) Este dendrograma muestra la jerarquía de agrupamiento de los hábitos estudiantiles utilizando el método de liga simple. El eje vertical representa la distancia euclídea, con una escala que va de 0.0 a 0.7. El eje horizontal representa a los estudiantes. Se observan dos grupos principales: uno a la izquierda coloreado en naranja y otro a la derecha coloreado en verde. El grupo naranja se divide en tres subgrupos, y el grupo verde se divide en cuatro subgrupos. La distancia de fusión final entre los dos grupos principales es superior a 0.7.
Método Ward: La distancia euclídea para 3 segmentos entre 50 y 75, mientras que para 4 segmentos está entre 40 y 50.	 Dendrograma de Hábitos Estudiantiles (Método Ward) Este dendrograma muestra la jerarquía de agrupamiento de los hábitos estudiantiles utilizando el método de Ward. El eje vertical representa la distancia euclídea, con una escala que va de 0 a 120. El eje horizontal representa a los estudiantes. Se observan dos grupos principales: uno a la izquierda coloreado en naranja y otro a la derecha coloreado en verde. El grupo naranja se divide en tres subgrupos, y el grupo verde se divide en cuatro subgrupos. La distancia de fusión final entre los dos grupos principales es superior a 120.

Liga Promedio: 'average'




Comparativo vs Métodos k-Means

k-Means directo:

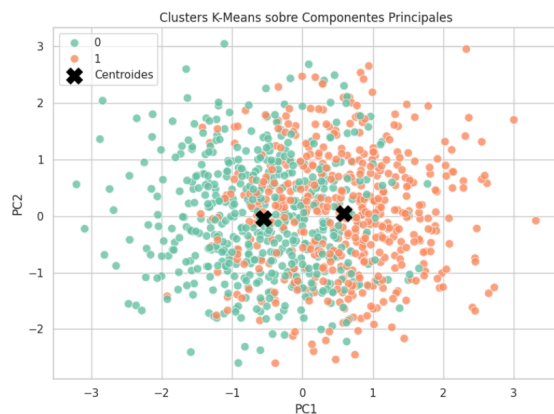
Aplicado a la base de información sin pasar por UMAP.

Logra reconocer 3 clusters aunque se aprecian algunos puntos verdes y azules muy cercanos a los naranjas en la parte superior.




PROCESAMIENTO E

- Se **imputó** la variable "parental_education_level" (9 missings)
- Se **normalizaron** las variables que en la base de datos original eran **numéricas**.
- Se **codificaron** las variables categóricas.



En este procesamiento se aplicaron tres criterios para






aplicaron tres criterios para determinar el número óptimo de clusters: **Método del Codo**, **Validación Cruzada del SSE Ratio** y **Coefficiente de Silueta (Silhouette Method)**.

Tanto el método del codo como la validación cruzada muestran una reducción importante del error al pasar de 1 a 2 ó 3 clusters, pero sin un punto de inflexión claramente definido.

Por otro lado, el coeficiente de silueta alcanza su máximo en $K=2$, aunque con un valor bajo (≈ 0.08), indicando una separación débil entre grupos.

En conjunto, la evidencia sugiere que una solución de **2 clusters** es la más consistente; sin embargo, los bajos valores de Silhouette indican que dichos grupos presentan un elevado traslape y una separación limitada.



Posteriormente se evaluó el uso de **PCA** como técnica de reducción de dimensionalidad de donde obtuvimos que convenía conservar 12 componentes principales para explicar al menos el 90% de la variabilidad, lo que sugiere una estructura de datos más compleja y menos correlacionada.

Si las observaciones tuvieran perfiles muy definidos, normalmente las primeras componentes capturarían gran parte de

la variabilidad.

Esto hubiera sugerido que los hábitos de los estudiantes no forman segmentos naturales bien definidos, sino que existe un comportamiento continuo con diferencias graduales entre individuos.

Hallazgos

Se identificaron agrupamientos **claramente definidos** en la base simulada de hábitos estudiantiles.



Los análisis mostraron de manera consistente que los resultados fueron más robustos al trabajar con los datos **sin aplicar procesos de normalización**.

Estos hallazgos subrayan la importancia de un procesamiento adecuado y estratégico de la información, condición indispensable para obtener conclusiones explicativas y confiables.



Gracias!

La bibliografía de este documento es la incluida en el Documento I.